DETECTION DE FRAUDES DANS LE DOMAINE DE L’ASSURANCE

➢ I. Exploration et visualisation des données

Dans le contexte de ce projet d'analyse de données, une première étape a été dédiée à l'exploration et à la visualisation des données contenues dans le fichier "Data_Projet_1.csv". Le but étant de fournir une compréhension approfondie de la structure du jeu de données, de la répartition des classes et des caractéristiques des variables clés.

Dans un premier temps, on procède à la configuration du répertoire de travail par l’utilisation de la fonction setwd(), de manière à s’assurer que les fichiers nécessaires seront correctement accessibles depuis le Dekstop. La fonction getwd() permet de procéder à une vérification concernant la commande précedente.

Ensuite, on installe et on charge les bibliothèques "readr", "dplyr", et "ggplot2" pour la manipulation et la visualisation des données. Les données ont été chargées dans un data frame appelé "fraudulent" à l'aide de la fonction read.csv(), suivi de la vérification de la structure et des statistiques élémentaires avec :

- str() : qui fournit des informations sur la structure du data frame ‘’fraudulent’’. On y observe à la première ligne le type de cet objet, il s’agit donc bien ici d’un ‘’data.frame’’ ainsi que le nombre d’observations (lignes), à savoir 1100, et de variables (colonnes) au nombre de 12. De plus, chaque variable est répertoriée avec son nom, suivi de deux-points et du type de données associé. Cela permet de vérifier rapidement le type de chaque variable (int, factor, num) dans le data frame. Enfin, les premières valeurs de chaque variable sont fournies, ce qui permet d'avoir un aperçu des données et de détecter d'éventuelles anomalies ou erreurs.

- names() : qui permet de récupérer les noms des variables présentes dans le data frame "fraudulent (claim id, customer id, age, gender…)

- summary() : qui fournit des tendances générales concernant les statistiques sommaires de chacune des variables du data frame fraudulent. Ces données comprennent des mesures centrales (moyenne, médiane), des valeurs minimales et maximales, ainsi que des quartiles. Par exemple, on observe que la variable "Age" présente une distribution allant de 18 à 79 ans, avec une moyenne d'environ 47,8 ans. ; la variable "Days_to_incident" présente des valeurs allant de 2 à 14 991 jours, avec une moyenne d'environ 2 814 jours ; la variable "Claim_amount" indique les montants de réclamation, avec des valeurs allant de 1 000 à 48 150.

Pour faciliter la manipulation des données pour la suite de notre étude, les noms des colonnes ont été uniformisés en majuscules à l'aide de la bibliothèque "stringr".

Avant de débuter le grand travail d'exploitation des données, on commence par faire une série de visualisation graphique pour se rendre compte de l'allure globale de nos données, que l'on récapitule ci dessous.

Présentation des données initiales

Fig. 1. Graphique sectoriel représentant la répartition des fraudes dans le dataset

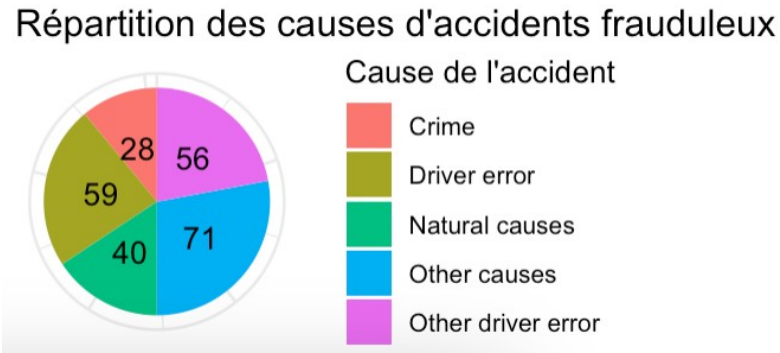

Fig.2. Graphique sectoriel représentant la répartition des causes d'accidents frauduleux

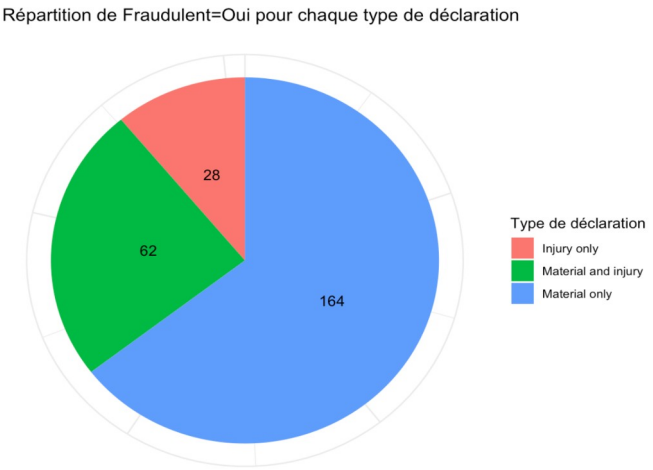

Fig.3. Graphique sectoriel représentant la répartition des types de déclarations frauduleuses

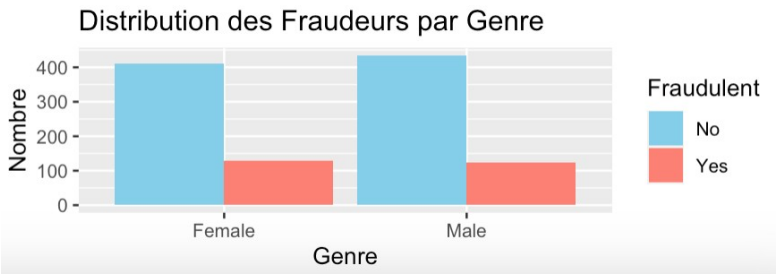

Fig. 4. Diagramme en barre représentant la distribution des fraudeurs ou non par Genre

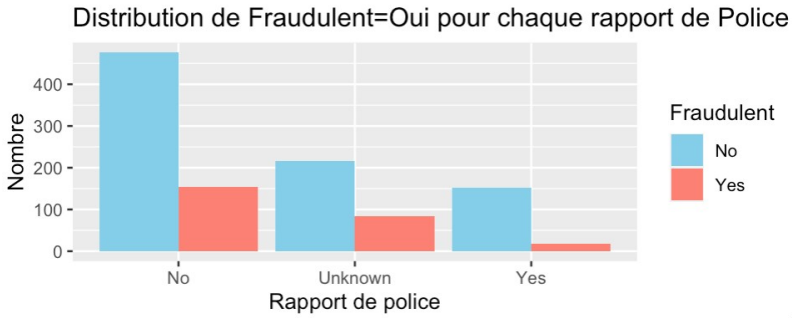

Fig. 5. Diagramme en barre représentant la distribution des fraudeurs pour chaque rapport de Police

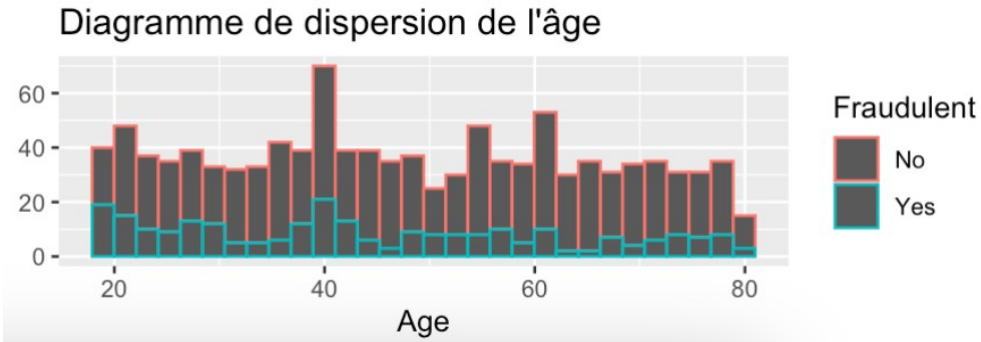

Fig. 6. Diagramme de dispersion représentant l'âge en fonction de la variable 'Fraudulent'

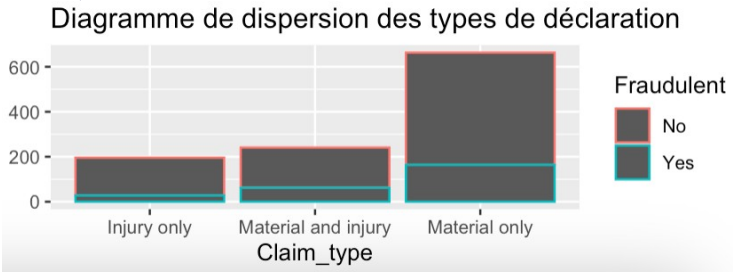

Fig. 7. Diagramme de dispersion représentant les types de déclaration en fonction de la variable 'Fraudulent'

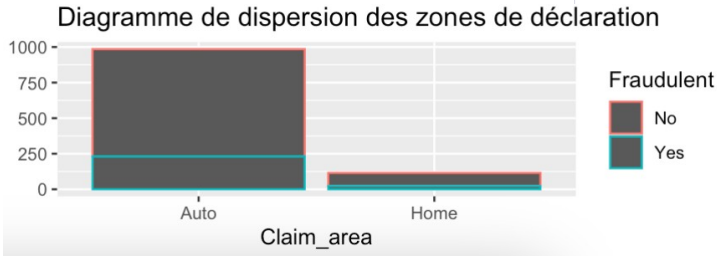

Fig. 8. Diagramme de dispersion représentant les zones de déclaration en fonction de la variable 'Fraudulent'

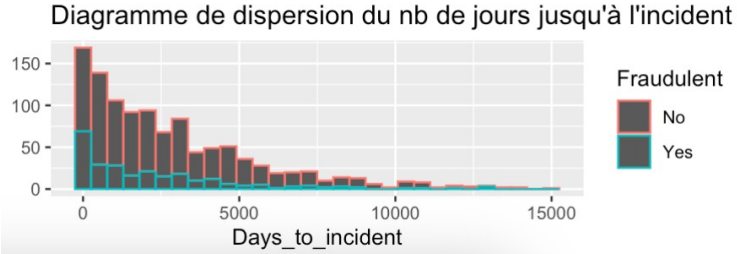

Fig. 9. Diagramme de dispersion représentant le nb de jours jusqu'à l'incident en fonction de la variable 'Fraudulent'

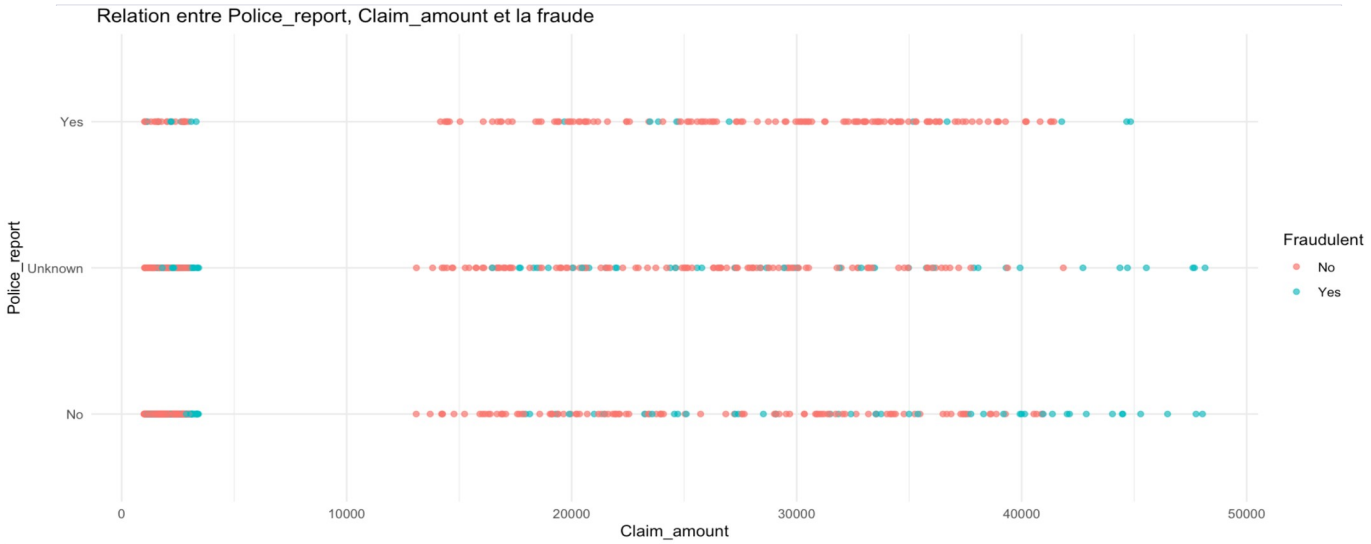

Fig. 10. Nuage de points montrant la relation entre Police_report, Claim_amount et la variable 'Fraudulent'

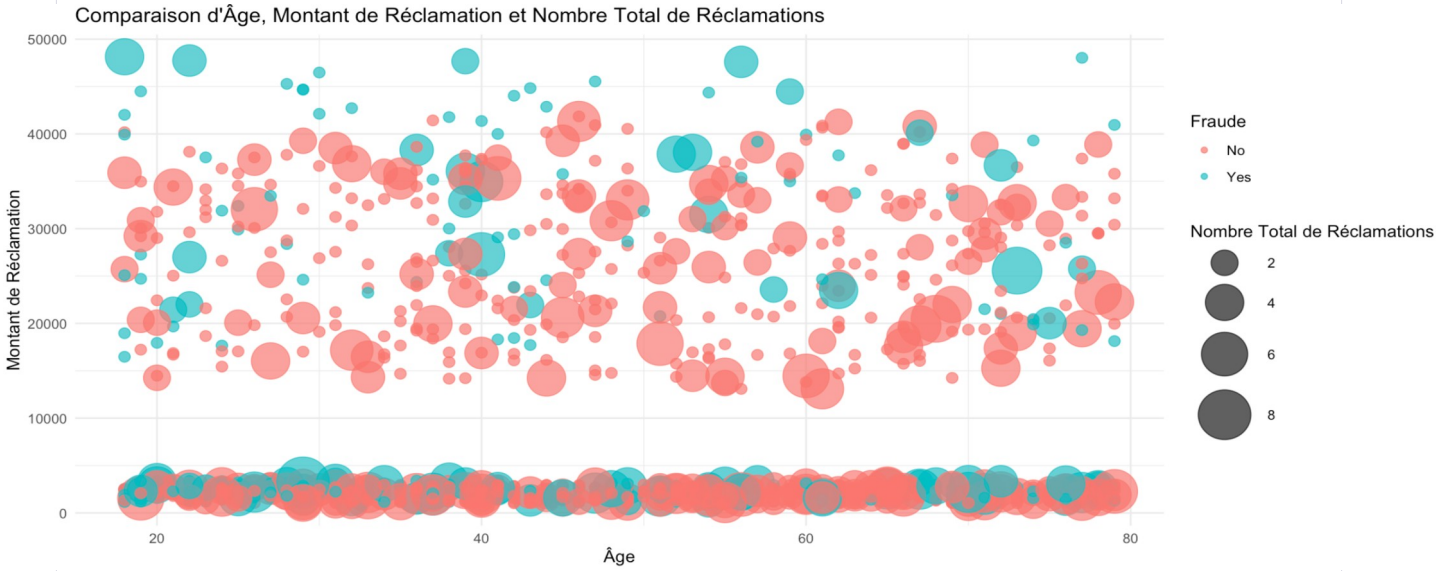

Fig. 11. Diagramme à Bulles permettant de comparer l'âge, le montant de réclamation et nombre total de réclamations

b) Problèmes

A l'aide de la commande str(), un premier problème observé concerne la colonne "Police Report" : celle-ci semble contenir des informations de type "Unknown". Afin de mieux comprendre l'ampleur de cette occurrence, on effectue une analyse spécifique pour identifier le nombre d'occurrences de ces valeurs : les résultats indiquent qu'il y a 300 occurrences de valeurs "Unknown" dans cette colonne. Cette information peut donc avoir des implications significatives sur la qualité des données, car ces valeurs manquantes pourraient potentiellement influencer les analyses futures.

La question est donc de savoir comment traiter ces valeurs "Unknown". Si l'on supprime les lignes concernées, cela réduirait notre base de données de 1100 observations à 800 observations, avec un nombre de 'Fraudulent = No' beaucoup plus élevé que 'Fraudulent = Yes', ce qui n'est pas intéressant pour notre futur modèle de prédiction, étant donné que l'on veut prédire les risques de fraudes à l'assurance.

On pourrait alors songer à supprimer complètement cette colonne.. mais avant cela, il est nécessaire de savoir si les informations qu'elle contient font d'elle une colonne importante, ce que l'on verra dans la partie suivante.

En poursuivant notre exploration, on peut constater un second problème : en effet, en filtrant les instances du data frame par classe ("Fraudulent=Yes" et "Fraudulent=No") et en utilisant la fonction table(), on observe que le jeu de données compte 254 observations frauduleuses (Yes) et 846 observations non frauduleuses (No). La distribution des classes révèle donc un certain déséquilibre, qui lors de la modélisation, peut influencer la performance des algorithmes de classification et conduire à une performance non optimale dans la détection de fraudes, étant donné que le modèle peut être incliné vers la classe majoritaire, à savoir, 'Fraudulent = No'.

Il est donc, encore une fois, nécessaire d'étudier de manière plus approfondie nos données et d'een dégager les variables les plus utiles.

c) Etudes des variables de l'ensemble de données

i) Tests de dépendance entre les variables discrètes : Chi-2 & Fischer

	X-squared	df	p-value
Genre et Fraudulent	0.42929	1	0.5123
Incident et Fraudulent	1.1564	4	0.8852
Claim_area et Fraudulent	0.51019	1	0.4751
Police_report et Fraudulent	20.592	2	3.377e-05
Claim_type et Fraudulent	10.51	2	0.005222

	p-value	Intervalle de confiance	Rapport de cotes
Genre et Fraudulent	0.4751	[0.6738921, 1.2050467]	0.9013061
Incident et Fraudulent	0.8839	/	/
Claim_area et Fraudulent	0.4829	[0.4814214, 1.3362535]	0.8161714
Police_report et Fraudulent	8.821e-06	/	/
Claim_type et Fraudulent	0.003681	/	/

Fig. 12. Tableaux représentant les résultats des tests de dépendance entre variables discrètes : test de Chi-2 (en noir) & test de Fischer (en bleu)

<u>Observations importantes :</u>

- Police_report & Claim_type ont une p-value très faible et <0.05 : 3.377e-05 et 0.005222 respectivement selon le test de Chi-2, 8.821-e06 et 0.003681 respectivement selon le test de Fisher. On en déduit que ces deux variables semblent être importantes pour prédire la fraude.

- Les autres variables n’ont pas l’air de montrer de relation significative avec la fraude, étant donné leur p-value > 0.05, ce qui indique qu'il n'y a pas suffisamment de preuves pour rejeter l'hypothèse nulle selon laquelle ces deux variables sont indépendantes.

ii) Tests de dépendance entre valeurs de variables discrètes : rprop() et chisq.residuals()

(a) rprop()

	No	Yes	Total
Female	76.0	24.0	100.0
Male	77.8	22.2	100.0
All	76.9	23.1	100.0

Fig 13. Table de contingence représentant les pourcentages de la classe Fraudulent pour Gender

	No	Yes	Total
Auto	76.5	23.5	100.0
Home	80.0	20.0	100.0
All	76.9	23.1	100.0

Fig 14. Table de contingence représentant les pourcentages de la classe Fraudulent pour Claim_area

	No	Yes	Total
No	75.6	24.4	100.0
Unknown	72.3	27.7	100.0
Yes	90.0	10.0	100.0
All	76.9	23.1	100.0

Fig 15.Table de contingence représentant les pourcentages de la classe Fraudulent pour Police_report

	No	Yes	Total
Injury only	85.7	14.3	100.0
Material and injury	74.3	25.7	100.0
Material only	75.3	24.7	100.0
All	76.9	23.1	100.0

Fig 16. Table de contingence représentant les pourcentages de la classe Fraudulent pour Claim_type

	No	Yes	Total
Crime	74.5	25.5	100.0
Driver error	77.5	22.5	100.0
Natural caus	78.8	21.2	100.0
Other causes	75.5	24.5	100.0
Other driver	77.5	22.5	100.0
All	76.9	23.1	100.0

Fig 17. Table de contingence représentant les pourcentages de la classe Fraudulent pour Incident_cause

<u>Interprétation des tables de contingences obtenues par rprop():</u>

- **Gender** : environ 24% des réclamations avec fraude sont faites par des femmes, tandis que les hommes représentent environ 22%. Cependant, la répartition globale entre les deux groupes (frauduleux et non frauduleux) reste relativement équilibrée ; il n’y a peut être donc pas de liens entre le genre et la fraude.

- **Incident_cause** : les différentes causes d'incidents semblent avoir des variations minimes entre les groupes frauduleux et non frauduleux. On ne dégage pas non plus de potentiel liens avec la fraude.

- **Claim_area** : les réclamations pour la zone "Home" ont une proportion légèrement plus basse de fraude (environ 20%) par rapport à celles de la zone "Auto" (environ 23,5%). Pas de lien évident.

- **Police_report** : en l'absence de rapport de police, la proportion de fraudes est d'environ 24.4%. Lorsque l'information sur le rapport de police est inconnue (« Unknown ») , cette proportion augmente à 27.7%. En revanche, lorsque le rapport de police est disponible, la proportion de fraudes diminue à seulement 10.0%. Ainsi, cela suggère que la présence ou l'absence d'un rapport de police pourrait être un indicateur utile pour prédire la fraude.

- **Claim_type** : on observe des variations dans la proportion de fraudes en fonction du type de réclamation ; en effet, les réclamations liées à des blessures uniquement ont une proportion plus faible de fraude (environ 14,3%) par rapport à celles liées à des blessures matérielles (environ 25,7%) ou à des biens matériels uniquement (environ 24,7%). Ainsi, cela suggère qu’il y a sûrement une association entre le type de réclamation et la fraude.

(b) Chisq.residuals()

	No	Yes	Total
Female	-0.1	0.2	0.0
Male	0.1	-0.2	0.0
All	0.0	0.0	0.0

Fig 18. Table de contingence représentant les résidus des test de chi-2 de la classe Fraudulent pour chaque valeurs de la variable Gender

	No	Yes	Total
Auto	-0.1	0.3	0.0
Home	0.2	-0.5	0.0
All	0.0	0.0	0.0

es test de variable

	No	Yes	Total
No	-0.3	0.7	0.0
Unknown	-0.7	1.4	0.0
Yes	1.3	-2.5	0.0
All	-0.2	0.4	0.0

Fig 20. Table de contingence représentant les résidus des test de chi-2 de la classe Fraudulent pour chaque valeurs de la variable Police_report

	No	Yes	Total
Injury only	0.9	-1.6	0.0
Material and injury	-0.4	0.8	0.0
Material only	-0.3	0.6	0.0
All	-0.1	0.2	0.0

Fig 21. Table de contingence représentant les résidus des test de chi-2 de la classe Fraudulent pour chaque valeurs de la variable Claim_type

	No	Yes	Total
Crime	-0.3	0.5	0.0
Driver error	0.1	-0.1	0.0
Natural caus	0.2	-0.4	0.0
Other causes	-0.1	0.3	0.0
Other driver	0.1	-0.1	0.0
All	0.0	0.0	0.0

Fig 22. Table de contingence représentant les résidus des test de chi-2 de la classe Fraudulent pour chaque valeurs de la variable incident_cause

<u>Interprétation des tables de contingence obtenues par chisq.residuals():</u>

- **Gender** : les résidus indiquent des différences très faibles entre les fréquences observées et attendues, ce qui suggère que le genre n'a pas une influence significative sur la fraude.

- **Incident_cause** : les résidus montrent des écarts modestes entre les fréquences observées et attendues pour chaque catégorie de cause d'incident, mais aucune tendance claire n'émerge ; ainsi, aucune cause spécifique ne semble fortement liée à la fraude.

- **Claim_area** : les résidus suggèrent des différences modérées entre les fréquences observées et attendues pour les zones "Auto" et "Home" ; ces différences ne sont cependant pas très prononcées.

- **Police_report** : les résidus montrent des différences importantes entre les fréquences observées et attendues, indiquant que la présence ou l'absence de rapport de police contribue significativement à la prédiction de la fraude.
- **Claim type** : les fréquences observées et attendues ne diffèrent pas de manière significative ; on pourrait alors songer à une faible corrélation entre cette variable et celle associée à la fraude.

iii) Mesures de corrélation entre variables numériques

	t	df	p-value	Intervalle de confiance (95%)	cor
Age & Claim_amount	-0.17883	1098	0.8581	[-0.06448306 , 0.05372733]	-0.005396722
Days_to_incident & Claim_amount	-1.5075	1098	0.132	[-0.10427448 , 0.01369602]	-0.04544768
Total_policy_claims & Claim_amount	-0.4133	1098	0.6795	[-0.07152615 , 0.04666934]	-0.01247197
Customer_ID & Claim_amount	-1.4177	1098	0.1566	[-0.10159624 , 0.01640233]	-0.04274602
Age & Total_policy_claims	2.1227	1098	0.034	[0.004841672 , 0.122574023]	0.06393029
Days_to_incident & Total_policy_claims	0.55914	1098	0.5762	[-0.04227756 , 0.07590273]	0.01687152

Fig 23. Tableau contenant les mesures de corrélation de Pearson entre différentes variables numériques

	S	p-value	rho
Age & Claim_amount	229097874	0.2778	-0.03274859
Days_to_incident & Claim_amount	232943739	0.09685	-0.05008534
Total_policy_claims & Claim_amount	218315892	0.5994	0.01585542
Customer_ID & Claim_amount	229845850	0.2313	-0.03612039
Age & Total_policy_claims	208799177	0.05139	0.05875575
Days_to_incident & Total_policy_claims	220370154	0.8271	0.00659503

Fig 24. Tableau contenant les mesures de corrélation de Spearman entre différentes variables numériques

	z	p-value	tau
Age & Claim_amount	-1.0758	0.282	-0.02184479
Days_to_incident & Claim_amount	-1.6724	0.09444	-0.03370895
Total_policy_claims & Claim_amount	0.52577	0.5991	0.01234489
Customer_ID & Claim_amount	-1.1654	0.2439	-0.02347648
Age & Total_policy_claims	1.9437	0.05193	0.04597551
Days_to_incident & Total_policy_claims	0.22186	0.8244	0.005208955

Fig 25. Tableau contenant les mesures de corrélation de Kendall entre différentes variables numériques

Interprétation :

Par exemple, pour les variables Claim_amount et Age, on a :

- Pearson : la corrélation de Pearson (**cor**) entre l'âge et le montant de la réclamation est extrêmement faible, avec un coefficient proche de zéro (-0,0054) + p-value = 0,8581 > 0,05
—> pas de corrélation significative entre les deux variables

- Spearman : la corrélation de rang de Spearman (**rho**) entre l'âge (**Age**) et le montant de la réclamation (**Claim_amount**) est de -0,0327 + p-value = 0,2778 > 0,05
—> pas de corrélation significative entre les deux variables

- Kendall : La corrélation de rang de Kendall (**tau**) entre l'âge et le montant de la réclamation est de -0,0218 + p-value = 0,282 > 0,05
—> pas de corrélation significative entre les deux variables

Ainsi, que ce soit par la méthode de Pearson, Spearman ou Kendall, ces méthodes confirment la faible corrélation entre l'âge et le montant de la réclamation.

En suivant le même procédé pour les autres couples de variables, on constate également qu’aucune des trois méthodes de test (Pearson, Spearman, et Kendall) ne montre une corrélation statistiquement significative entre ces couples; autrement dit, les variables numériques de notre ensemble de données ‘fraudulent’ seraient indépendantes entres elles.

iv) Mesures et variables les plus utiles

Afin de déterminer définitivement les variables les plus pertinentes en vue de la construction du modèle de prédiction des fraudes en assurance, on réalise diverses évaluations quant à l'importance de ces variables, synthétisées dans les tableaux suivants :

Variables	Information Gain
Claim_amount	0.0372646710
Days_to_incident	0.0242523016
Police_report	0.0155266566
Age	0.0121861405
Claim_type	0.0075046003
Total_policy_claims	0.0063010073
Customer_id	0.0057850571
Claim_id	0.0017908974
Incident_cause	0.0007560826
Claim_area	0.0004665990
Gender	0.0003463316

Variables	Gain Ratio
Claim_amount	0.2961253738
Customer_id	0.2129909327
Total_policy_claims	0.0622357851
Days_to_incident	0.0452141315
Age	0.0412640992
Claim_id	0.0234454496
Police_report	0.0111858138
Claim_type	0.0055036759
Claim_area	0.0009655619
Gender	0.0003463985
Incident_cause	0.0003354360

Variables	Index Gini
Claim_amount	0.0207928135
Days_to_incident	0.0133979433
Police_report	0.0066488522
Age	0.0064188069
Total_policy_claims	0.0034019002
Claim_type	0.0033934864
Customer_id	0.0032351914
Claim_id	0.0009573286
Incident_cause	0.0003733960
Claim_area	0.0002230818
Gender	0.0001705444

Variables	Relief
Age	0.077526080
Police_report	0.047272727
Claim_amount	0.041551177
Days_to_incident	0.034820909
Customer_id	0.030189818
Gender	0.023636364
Incident_cause	0.021818182
Claim_area	0.013636364
Claim_type	0.003636364
Claim_id	-0.001929784
Total_policy_claims	-0.017272727

Variables	MDL
Claim_amount	3.331895e-02
Days_to_incident	2.122457e-02
Age	8.955501e-03
Police_report	8.581268e-03
Customer_id	3.964458e-03
Total_policy_claims	3.531398e-03
Claim_type	7.507943e-04
Claim_id	-8.206771e-05
Claim_area	-2.568475e-03
Gender	-3.267669e-03
Incident_cause	-1.188655e-02

Observations :

- **Information Gain** : La variable "Claim_amount" se démarque avec un IG élevé, suggérant qu'elle apporte une quantité significative d'informations pour prédire la fraude. "Days_to_incident" et "Police_report" sont également des contributeurs importants.

- **Gain Ratio** : "Claim_amount" et "Customer_id" affichent des valeurs élevées de Gain Ratio, soulignant leur importance potentielle dans la prédiction. "Total_policy_claims" et "Days_to_incident" suivent également de près.

- **Index Gini** : Les variables "Claim_amount" et "Days_to_incident" montrent des valeurs élevées d'Index Gini, indiquant leur rôle dans la réduction de l'impureté des classes. "Police_report" présente également une certaine importance.

- **Relief** : Age" et "Police_report" se distinguent avec des valeurs élevées de Relief, suggérant qu'elles ont une capacité significative à distinguer les exemples positifs des exemples négatifs.

- **Minimum Description Length (MDL) :** De nouveau, "Claim_amount" et "Days_to_incident" émergent comme les variables les plus informatives selon MDL, indiquant leur capacité à compresser l'information nécessaire à la représentation des données.

Finalement, on constate à l’aide de ces mesures, que la variable la plus utile pour la prédiction des fraudes à l’assurance est « Claim_amount ». "Days_to_incident" et "Police_report" suivent également la tendance de cette variable de très près. En revanche, les variables les moins utiles, d’après ces mesures, semblent être : Claim_area, Incident Cause & Gender.

Conclusion de cette partie :

Après toutes ces analyses, plusieurs variables émergent comme étant particulièrement informatives pour la prédiction de fraudes à l'assurance, à savoir : Claim_amount, Days_to_incident et Police_report.

➢ II. Pré-traitement des données

Grâce à l’analyse effectuée au cours de la première partie de ce projet, on décide de supprimer les variables Gender, Claim_area et Incident_cause. Cette décision vise à concentrer l’analyse sur les aspects les plus significatifs du jeu de données, facilitant ainsi une compréhension plus claire des motifs et des tendances présents. De plus, les variables Claim_ID et Customer_ID ont également été exclues, car selon moi, elles ne fournissent pas d'informations utiles pour l'objectif poursuivi : on ne les utiliseras donc pas lors de l'apprentissage de l'arbre de décision.

Ensuite, on a effectué une vérification des lignes contenant des valeurs manquantes et le résultat de cette vérification a montré qu'il n'y avait pas de lignes avec des valeurs manquantes ('NA'). Par conséquent, aucune suppression de lignes n'a été nécessaire, et on laisse le jeu de données intact.

Enfin, aucune transformation des types des valeurs n'est nécessaire, car elles sont correctes dans leur forme actuelle.

➢ III. Extraction de clusters à partir des données

Afin de débuter cette troisième partie, on utilise l'algorithme des K-means pour effectuer un clustering par partitionnement. L'objectif était de regrouper les déclarations d'accidents similaires en clusters distincts, avec l'espoir que ces clusters pourraient révéler des tendances et des caractéristiques spécifiques liées à la fraude.

Avant d’extraire les clusters à partir des données, on commence par créer un objet appelé ‘dmatrix’, qui contient des informations sur les dissimilarités entre 1100 objets, présentant des valeurs allant de 0.0000381 à 0.9120300. Ces dissimilarités sont exprimées à travers une métrique mixte avec des types I (qualitatifs) et N (numériques). On observe que la médiane se situe à 0.3621900, indiquant une tendance vers des dissimilarités modérées.

Pour déterminer le nombre optimal de clusters K, on met en place une boucle variant K de 2 à 10. À chaque itération, on applique l'algorithme des K-means sur la matrice de dissimilarités dmatrix. Pour évaluer la performance de chaque configuration de K, une table de contingence a été générée, montrant la répartition des observations frauduleuses et non frauduleuses dans chaque cluster, comme on le voit ci-dessous :

	No	Yes
1	347	90
2	131	0
3	0	164
4	368	0

Fig 26. Table de contingence

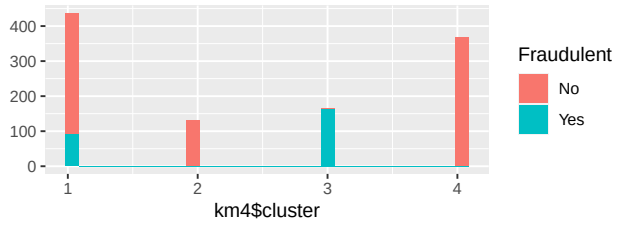

Fig 27. Représentation graphique de la table de contingence

On retient alors K = 4 comme le nombre optimal de clusters, car cette configuration offre une distinction raisonnable entre les déclarations frauduleuses et non frauduleuses, tout en évitant de créer un nombre excessif de clusters.

Ensuite, l'application de l'algorithme des K-means avec K=4 a généré les clusters suivants, chacun caractérisé par une répartition spécifique des classes Fraudulent=Oui/Non et des caractéristiques distinctes :

CLUSTER 1 : Ce cluster compte 347 observations non frauduleuses (No) et 90 frauduleuses (Yes).

Les caractéristiques spécifiques incluent :

Caractéristique	Non frauduleux	Frauduleux
Âge	Minimum=18, Maximum=79, Médiane=48	Minimum=18, Maximum=79, Médiane=41.5
Jours jusqu'à l'incident	Minimum=2, Maximum=12657, Médiane=2417	Minimum=2, Maximum=12657, Médiane=1127
Montant de la réclamation	Minimum=13090, Maximum=41850, Médiane=26890	Minimum=13090, Maximum=41850, Médiane=32154
Nb. total de réclamations d'assurance	Minimum=1, Maximum=7, Médiane=1	Minimum=1, Maximum=7, Médiane=1

Fig. 28 Tableau représentant les caractéristiques spécifiques aux variables catégorielles liées au cluster 1

CLUSTER 2 : Ce cluster compte 131 observations non frauduleuses (No) et aucune frauduleuse (Yes).

Les caractéristiques spécifiques incluent :

Caractéristique	Non frauduleux	Frauduleux
Âge	Minimum=19, Maximum=79, Médiane=52	/
Jours jusqu'à l'incident	Minimum=3, Maximum=14991 Médiane=2603	/
Montant de la réclamation	Minimum=1020 Maximum=2980, Médiane=2010	/
Nb. total de réclamations d'assurance	Minimum=1, Maximum=6, Médiane=1	/

Fig. 29 Tableau représentant les caractéristiques spécifiques aux variables catégorielles liées au cluster 2

CLUSTER 3 : Ce cluster compte aucune observation non frauduleuse et 164 observations frauduleuse (Yes).

Les caractéristiques spécifiques incluent :

Caractéristique	Non frauduleux	Frauduleux
Âge	/	Minimum=18, Maximum=79, Médiane=42
Jours jusqu'à l'incident	/	Minimum=2, Maximum=12117, Médiane=1524
Montant de la réclamation	/	Minimum=1150, Maximum=3427, Médiane=2277
Nb. total de réclamations d'assurance	/	Minimum=1, Maximum=8, Médiane=1

Fig. 30 Tableau représentant les caractéristiques spécifiques aux variables catégorielles liées au cluster 3

CLUSTER 4 : Ce cluster compte 368 observations non frauduleuses (No) et aucune frauduleuse (Yes).

Les caractéristiques spécifiques incluent :

Caractéristique	Non frauduleux	Frauduleux
Âge	Minimum=18, Maximum=79, Médiane=47	/
Jours jusqu'à l'incident	Minimum=2, Maximum=14020, Médiane=2036	/
Montant de la réclamation	Minimum=1000, Maximum=2990, Médiane=2070	/
Nb. total de réclamations d'assurance	Minimum=1, Maximum=6, Médiane=1	/

Fig. 31 Tableau représentant les caractéristiques spécifiques aux variables catégorielles liées au cluster 4

On analyse ensuite les caractéristiques spécifiques aux variables factorielles dans chaque cluster, que l’on récapitule dans le tableau ci-dessous :

Cluster	Fraudulent (No)	Fraudulent (Yes)	Police R- No	Police R - Unknown	Police R - Yes	Injury only	Material and injury	Material only
1	347	90	149	151	137	196	241	0
2	131	0	0	105	26	0	0	131
3	0	164	113	44	7	0	0	164
4	368	0	368	0	0	0	0	368

Fig. 32 Tableau dégageant les caractéristiques spécifiques aux variables factorielles dans chaque cluster

Interprétation pour chaque clusters

> Cluster 1

- Ce cluster est diversifié avec une variété de statuts de rapports de police et de types de réclamations.
- Il présente une répartition significative de cas frauduleux et non frauduleux.
- On ne peut pas en dégager un schéma clair.

> Cluster 2

- Les observations dans ce cluster ont principalement un type de réclamation "Matériel seulement".
- Aucun cas frauduleux (Oui) n'est présent dans ce cluster.
- Le statut du rapport de police est souvent inconnu.

> Cluster 3

- Toutes les observations sont étiquetées comme frauduleuses.
- Toutes les observations dans ce cluster ont un type de réclamation "Matériel seulement".
- Le statut du rapport de police varie, mais la plupart ont un statut "Non".

> Cluster 4

- Ce cluster est caractérisé par des observations sans cas frauduleux.
- La répartition du statut du rapport de police est clairement "Non" ; le type de réclamation est principalement "Matériel seulement".

Finalement, le cluster 3 étant le plus approprié à l’objectif de notre projet, on peut donc, de manière générale, relever les points suivants :

- Les fraudes ont tendance à être associées à des incidents signalés plus tôt.

- Les montants de réclamation pour les fraudes sont généralement élevés.

- La plupart des individus frauduleux semblent avoir un nombre médian de réclamations égal à 1.

- Les causes sont en majorité matérielles.

- Il n’y a souvent pas de rapport de police.

➢ IV. Définition de la méthode d'évaluation des classifieurs

La méthode d’évaluation que l’on va utiliser se divise en plusieurs étapes :

- La première étape est l’étude du taux de succès/échecs qui constitue une mesure fondamentale évaluant la capacité globale du modèle à prédire correctement les cas frauduleux et non frauduleux.

- La seconde étape est celle des matrices de confusion, qui offrent une vue détaillée des résultats de classification, distinguant les vrais positifs, vrais négatifs, faux positifs et faux négatifs.

- La troisième étape est celle des mesures d'évaluation, telles que la précision, le rappel, la spécificité et le F1-score, permettant ainsi d'obtenir des informations détaillées sur la performance du modèle.

Le processus d'évaluation comprend donc l'application des classifieurs aux données de test, l’analyse des matrices de confusion et enfin, le calcul des métriques d'évaluation telles que la précision, le rappel, la spécificité et le F1-score.

Pour pouvoir choisir le classifieur le plus pertinent, on se reposera sur le calcul des taux de succès et l'optimisation du F1-score (étant donné l'importance accordée à la précision et au rappel). De plus, des considérations spécifiques aux objectifs du modèle, tels que les poids accordés à la sensibilité à la détection des fraudes, à la spécificité et à la capacité du modèle à généraliser à de nouvelles données, sont pris en compte.

Cette méthodologie d'évaluation va donc garantir la sélection d'un classifieur répondant de manière équilibrée aux exigences spécifiques de notre modèle de prédiction des déclarations frauduleuses.

➢ V. Définition des données d'apprentissage et de test

Afin de mettre en œuvre la partie précédente, on va opter pour une approche par partitionnement, en divisant l’ensemble de données initial en deux parties distinctes : un ensemble d’apprentissage "fraudulent_EA" sur lequel les classifieurs seront construits, constitué des deux tiers de l'ensemble de données ; et un ensemble de test "fraudulent_ET" composé du dernier tiers de l'ensemble de données.

En effet, la division en ensembles d'apprentissage et de test permet de minimiser le risque de sur-apprentissage en évaluant la performance du modèle sur des données indépendantes. De plus, le paramétrage que l’on a choisi dans les ensembles d'apprentissage et de test, à savoir, environ 70 %-30 %, permettra d’assurer une évaluation juste de la performance du modèle pour chaque catégorie.

➢ VI. Construction et évaluation des classifieurs

Pour élaborer et évaluer les classifieurs basés sur les arbres de décision, on utilise trois algorithmes distincts : rpart, C50, et tree. Après avoir installé les bibliothèques nécessaires, on procède à l'apprentissage de chaque arbre. On utilise la bibliothèque rpart.plot pour visualiser graphiquement les arbres. Cependant, en raison d'un problème graphique ‘Error in plot.new() : figure margins too large’, on a dû ajuster les paramètres graphiques avant chaque visualisation à l'aide de la commande : par(mfrow = c(1, 1), mar = c(1, 1, 1, 1)).

Les arbres obtenus sont présentés ci-dessous :

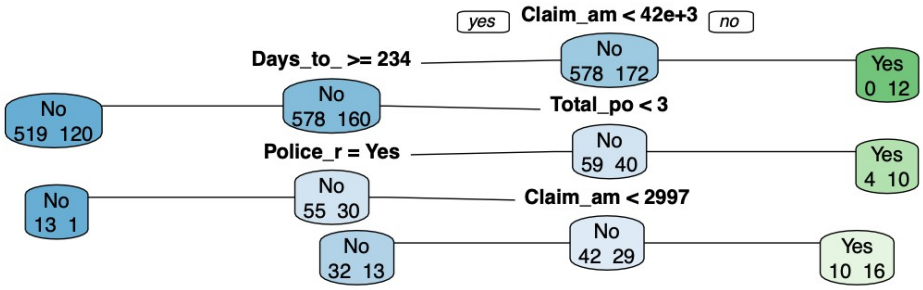

Fig 33. Représentation de l'arbre 'tree 1'

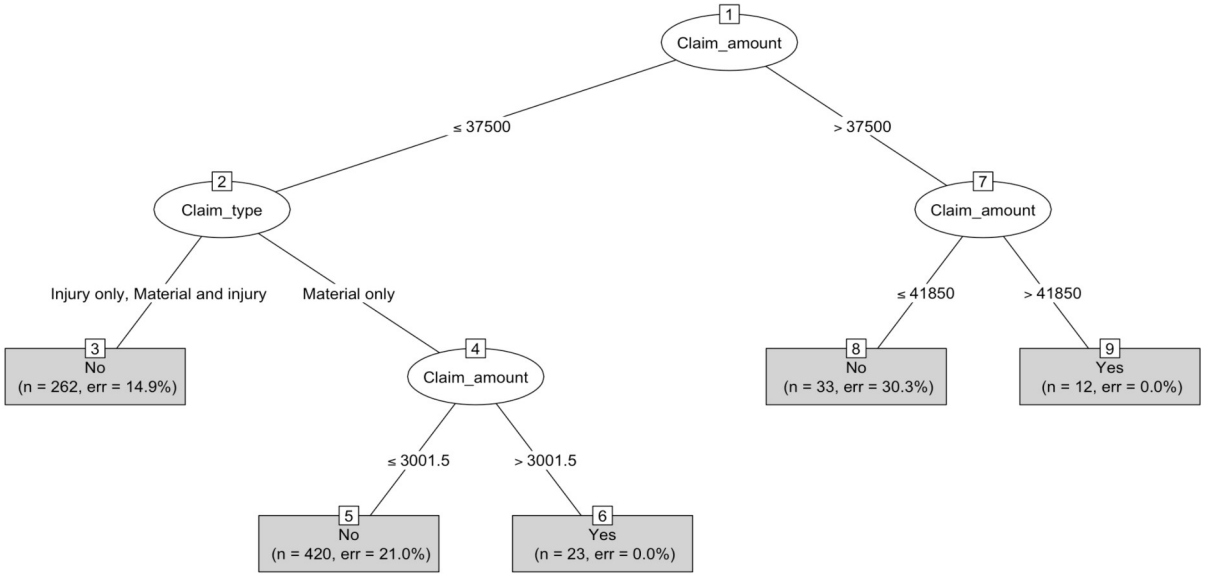

Fig 34. Représentation de l'arbre 'tree 2'

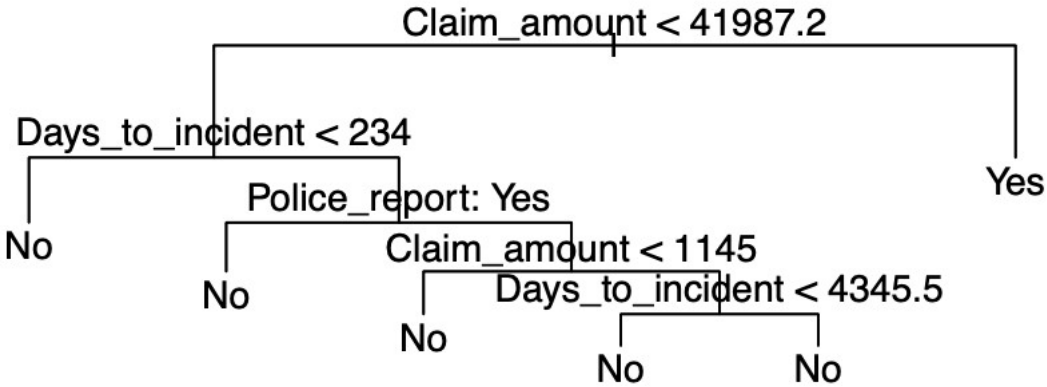

Fig 35. Représentation de l'arbre 'Tree 3'

Par la suite, on effectue le test des arbres et le calcul des taux de succès de chacun, comme récapitulé dans le tableau ci dessous :

Classifieur	test_treeN (No)	test_treeN (Yes)	Taux de succès
Tree 1	316	34	0.7829
Tree 2	331	19	0.82
Tree 3	343	7	0.7857

Fig 36. Tableau représentant le test et le taux de succès des différents arbres de décision

➢ VII. Choix du classifieur le plus performant

Dans le cadre de notre projet visant à détecter la fraude dans le domaine de l’assurance, le classifieur choisi est finalement tree2, l’arbre de décision C5.0.

Ce choix a été motivé par son taux de succès le plus élevé parmi les classifieurs considérés. En effet, avec un taux de succès de 82%, `tree2` a démontré une performance supérieure dans la classification des données, ce qui en fait un choix préféré pour la détection de fraudes.

De plus, la mesure de précision, qui évalue la fiabilité des prédictions positives, indique que `tree2` a une précision parfaite de 1, démontrant qu'il n'a fait aucune erreur en classifiant les exemples positifs. La spécificité, mesurant la capacité du classifieur à détecter les exemples négatifs, montre également une performance optimale de 1 pour `tree2`, indiquant qu'il a bien détecté tous les exemples négatifs de l'ensemble de test. Le taux de vrais négatifs, évaluant la fiabilité des prédictions négatives, montre que `tree2` a une performance élevée avec un score de 0.81, démontrant sa capacité à correctement classifier les exemples négatifs.

Concernant sa structure, cet arbre a été construit en utilisant la variable `Fraudulent ~ .` sur un ensemble de données comprenant 750 échantillons et 6 prédicteurs. La taille de l'arbre est de 5, ce qui facilite son interprétation étant donné qu’une petite taille conduit à une structure simple.

D’autre part, l'arbre se base principalement sur les attributs `Claim_amount` et `Claim_type` pour classifier les observations en classes `No` ou `Yes`. La condition initiale établit une division des données en deux branches, distinguant les réclamations dont le montant dépasse 37 500. Au sein de chaque branche, d’autres conditions telles que le type de réclamation sont considérées.

La matrice de confusion fournit une vision plus détaillée des performances du modèle sur les données d'entraînement. Ici, le modèle a correctement classé 578 observations comme `No` et 35 observations comme `Yes`. Cependant, il a commis 137 erreurs, dont 137 observations de la classe `No` ont été incorrectement classées comme `Yes`. Ainsi, on pourrait en déduire que le résultat obtenu souligne la nécessité d'équilibrer la sensibilité et la spécificité du modèle, car il semble plus enclin à classer des réclamations non frauduleuses comme frauduleuses.

➢ VIII. Application du classifieur aux données à prédire

Dans cette dernière partie, on va appliquer l'arbre de décision sélectionné, à savoir, tree 2, pour prédire la classe des instances de l’ensemble de données "Data_Projet_1_New.csv".
Ce nouvel ensemble de données contient les informations sur 200 nouvelles déclarations pour lesquels la société souhaite prédire s’il y a un risque de fraude.

Après avoir tapé la commande ‘table()’, on obtient le résultat ci-dessous :

```
> table(predictions)
predictions
 No Yes
192   8
```

On voit que sur les 200 observations, 192 ont été classées comme "No" (non frauduleuses) et 8 comme "Yes" (frauduleuses). Ainsi, la majorité des nouvelles observations sont susceptibles d'être non frauduleuses selon le modèle.

Par ailleurs, en observant les probabilités associées à chaque prédiction, on constate que les valeurs minimales pour la classe "No" sont relativement élevées, dépassant fréquemment 0,7, tandis que les probabilités minimales pour la classe "Yes" sont plus faibles. Les valeurs maximales et moyennes des probabilités reflètent également cette tendance, soulignant la confiance du modèle dans ses prédictions.

La structure des données de sortie montre que les prédictions sont stockées sous forme de facteur avec deux niveaux : "No" et "Yes". Enfin, la matrice de probabilités est une structure de données numériques avec des valeurs de probabilité pour chaque classe.

Conclusion

Pour conclure, lors du processus d'exploration des données, plusieurs observations importantes ont émergées. La variable "Claim_amount" s'est révélée être un prédicteur crucial pour la détection de fraudes, ainsi que "Days_to_incident" et "Police_report". L’analyse de clustering nous a, d’autre part, permis d'identifier des tendances spécifiques associées aux fraudes, notamment en mettant en évidence le Cluster 3 comme particulièrement pertinent pour notre objectif.

La méthodologie d'évaluation des classifieurs, comprenant l’étude du taux de succès, des matrices de confusion et des mesures d'évaluation, a permis de sélectionner le classifieur tree 2, jugé comme étant le plus performant. Ce choix a été dicté par un taux de succès élevé de 82%, ainsi que par une précision, un rappel, et une spécificité optimaux.

Cependant, certaines difficultés ont été rencontrées au cours de l'analyse. En effet, des problèmes graphiques ont été observés lors de la visualisation des arbres de décision, nécessitant des ajustements paramétriques pour chaque visualisation. De plus, la tendance du modèle à classer des réclamations non frauduleuses comme frauduleuses, comme indiqué par la matrice de confusion, souligne la nécessité d'équilibrer la sensibilité et la spécificité pour des résultats optimaux.

Enfin, l'application du modèle à de nouvelles données a fourni des prédictions majoritairement orientées vers des déclarations non frauduleuses, avec une confiance élevée dans ces prédictions. On pourrait cependant, afin d’améliorer le processus de détection de fraudes à l’assurance, penser à trouver le moyen de traiter les déséquilibres dans les classes et celui d’optimiser la balance entre la sensibilité et la spécificité.